iniciar Abrir no aplicativo

Grace Zhang

Seguir 142 seguidores Cerca de

Qual é o truque do kernel? Por que isso é importante?

Grace Zhang 11 de novembro de 2018 · 5 min de leitura

Ao falar sobre kernels no aprendizado de máquina, provavelmente a primeira coisa que vem à sua mente é o modelo de máquinas de vetores de suporte (SVM), porque o truque do kernel é amplamente usado no modelo SVM para unir linearidade e não linearidade.

Fundamentos de máquinas de vetor de suporte

Para ajudá-lo a entender o que é um kernel e por que ele é importante, vou apresentar os fundamentos do modelo SVM primeiro.

O modelo SVM é um modelo de aprendizado de máquina supervisionado que é usado principalmente para classificações (mas também pode ser usado para regressão!). Ele aprende como separar grupos diferentes, formando limites de decisão.

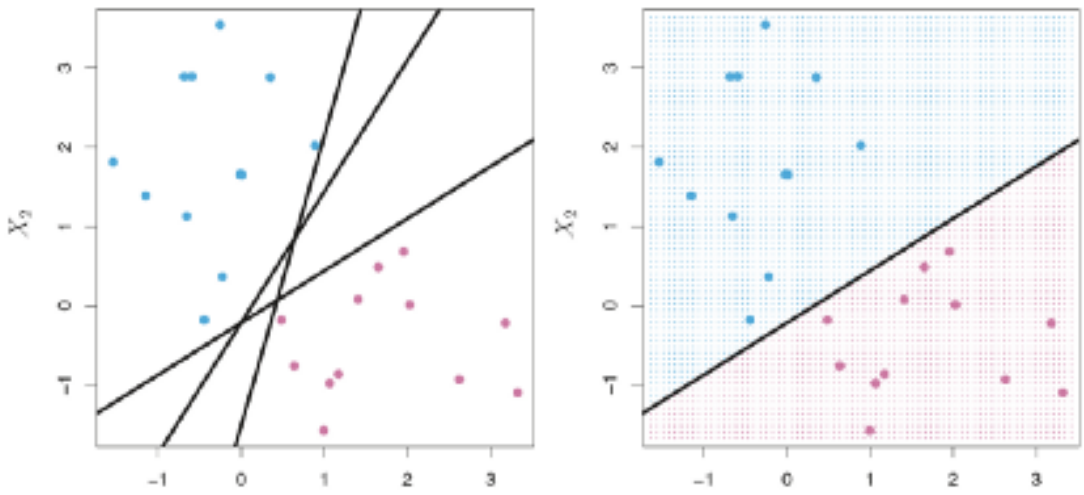

iniciar Abrir no aplicativo

No gráfico acima, notamos que existem duas classes de observações: os pontos azuis e os pontos roxos. Existem várias maneiras de separar essas duas classes, conforme mostrado no gráfico à esquerda. No entanto, queremos encontrar o "melhor" hiperplano que possa maximizar a margem entre essas duas classes, o que significa que a distância entre o hiperplano e os pontos de dados mais próximos em cada lado é a maior. Dependendo de qual lado do hiperplano um novo ponto de dados localiza, poderíamos atribuir uma classe para a nova observação.

Parece simples no exemplo acima. No entanto, nem todos os dados são linearmente separáveis. Na verdade, no mundo real, quase todos os dados são distribuídos aleatoriamente, o que torna difícil separar diferentes classes linearmente.

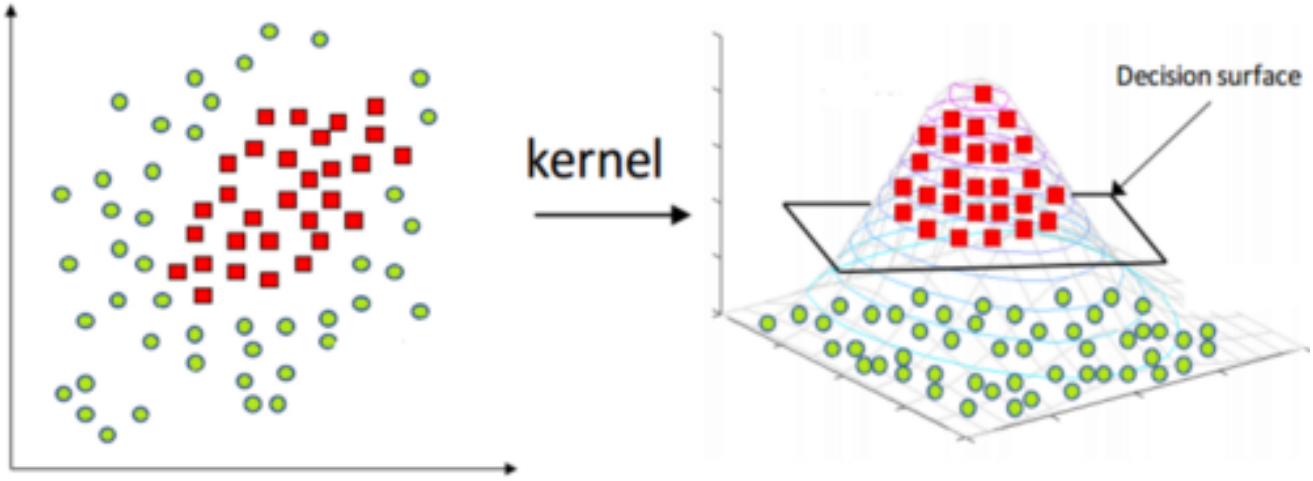

Por que é importante usar o truque do kernel?

Como você pode ver na imagem acima, se encontrarmos uma maneira de mapear os dados do espaço bidimensional para o espaço tridimensional, seremos capazes de encontrar uma superfície de decisão que divide claramente entre as diferentes classes. Meu primeiro pensamento sobre esse processo de transformação de dados é mapear todos os pontos de dados para uma dimensão superior (neste caso, 3 dimensões), encontrar o limite e fazer a classificação.

Isso soa bem. No entanto, quando há mais e mais dimensões, os cálculos dentro desse espaço se tornam cada vez mais caros. É aí que entra o truque do kernel.Ele nos permite operar no espaço de recurso original sem computar as coordenadas dos dados em um espaço dimensional superior.

iniciar Abrir no aplicativo

$$\mathbf{x} = (x_1, x_2, x_3)^T$$
$$\mathbf{y} = (y_1, y_2, y_3)^T$$

Aqui x e y são dois pontos de dados em 3 dimensões. Vamos supor que precisamos mapear xey para um espaço de 9 dimensões. Precisamos fazer os seguintes cálculos para obter o resultado final, que é apenas um escalar. A complexidade computacional, neste caso, é O (n^2).

$$\phi(\mathbf{x}) = (x_1^2, x_1x_2, x_1x_3, x_2x_1, x_2^2, x_2x_3, x_3x_1, x_3x_2, x_3^2)^T$$
$$\phi(\mathbf{y}) = (y_1^2, y_1y_2, y_1y_3, y_2y_1, y_2^2, y_2y_3, y_3y_1, y_3y_2, y_3^2)^T$$

$$\phi(\mathbf{x})^T\phi(\mathbf{y}) = \sum_{i,j=1}^{3} x_ix_jy_iy_j$$

No entanto, se usarmos a função kernel, que é denotada como k (x, y), em vez de fazer cálculos complicados no espaço 9-dimensional, alcançamos o mesmo resultado dentro do espaço tridimensional calculando o produto escalar de x -transpor e y. A complexidade computacional, neste caso, é O (n).

$$\begin{aligned} k(\mathbf{x}, \mathbf{y}) &= (\mathbf{x}^T\mathbf{y})^2 \\ &= (x_1y_1 + x_2y_2 + x_3y_3)^2 \\ &= \sum_{i,j=1}^{3} x_ix_jy_iy_j \end{aligned}$$

iniciar Abrir no aplicativo

aplicação do truque do kernel não se limita ao algoritmo SVM. Quaisquer cálculos envolvendo os produtos escalares (x, y) podem utilizar o truque do kernel.

Diferentes funções do kernel

Existem diferentes kernels. Os mais populares são o kernel polinomial e o kernel de função de base radial (RBF).

"Intuitivamente, o kernel polinomial olha não apenas para as características fornecidas das amostras de entrada para determinar sua similaridade, mas também combinações delas" (Wikipedia), assim como o exemplo acima. Com n recursos originais ed graus de polinômio, o kernel do polinômio produz n ^ d recursos expandidos.

$$k(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^T \mathbf{y} + 1)^d$$

O formato do kernel polinomial

O kernel RBF também é chamado de kernel Gaussiano. Há um número infinito de dimensões no espaço de recursos porque ele pode ser expandido pela Série de Taylor. No formato abaixo, o parâmetro γ define quanta influência um único exemplo de treinamento tem. Quanto maior for, mais próximos os outros exemplos devem ser afetados (documentação do sklearn).

$$k(\mathbf{x}, \mathbf{y}) = e^{-\gamma \|\mathbf{x}-\mathbf{y}\|^2}, \gamma > 0$$

O formato do kernel RBF

Existem diferentes opções para as funções do kernel na biblioteca sklearn em Python. Você pode até construir um kernel personalizado, se necessário.

O fim

iniciar Abrir no aplicativo

de que possamos ajustar o modelo em excesso. Assim, a escolha da função de kernel certa (incluindo os parâmetros corretos) e a regularização são de grande importância.

Se você está curioso sobre o que é regularização, escrevi um artigo falando sobre o meu entendimento e você pode encontrá-lo aqui .

Espero que você aproveite este artigo. Como sempre, entre em contato se tiver dúvidas, comentários, sugestões etc. Obrigado por ler :)

Referência:

O que são kernels no aprendizado de máquina e SVM e por que precisamos deles?

Método Kernel - Wikipedia

Funções do kernel por Tejumade Afonja

Funções de kernel para aprendizado de máquina por PERPETUAL ENIGMA

MSDS621 Machine Learning na University of San Francisco

Sobre mim:

Eu sou um estudante de mestrado em Ciência de Dados na University of San Francisco. Sou muito apaixonado por Aprendizado de Máquina e PNL. Eu gosto de fazer caminhadas no meu tempo livre. Você também pode me encontrar através do Linkedin .

Aprendizado de Máquina Ciência de Dados Guia do iniciante Classificação

iniciar Abrir no aplicativo

CercaAjudaJurídico de

Obtenha o aplicativo Medium

Download on the App Store

GET IT ON Google Play